

08/08/2025

Analyse des documents scientifiques :

MULTIMODAL EMOTION RECOGNITION USING DEEP LEARNING


&

MULTIMODAL EMOTION RECOGNITION IN RESPONSE TO VIDEOS

REALISER PAR: ASMA BENZAIED

MULTIMODAL EMOTION RECOGNITION USING DEEP LEARNING

LECTURE MULTIMODALE




TEXTES



AUDIO




CARTES/
GRAPHIQUES



SITES
INTERNET



IMAGES/
PHOTOS



FILMS/
VIDÉOS

Le document de recherche "**Multimodal Emotion Recognition using Deep Learning**" est une revue approfondie des méthodes existantes pour la reconnaissance des émotions multimodales en utilisant des techniques d'apprentissage profond.

1. Nature du Document:

- **Type** : Il s'agit d'une **revue systématique** qui synthétise et compare les travaux récents (2019-2020) sur la reconnaissance des émotions multimodales.

• Objectif principal :

1. Passer en revue les architectures de deep learning (CNN, LSTM, SVM, etc.) et les modalités (audio, texte, images, signaux physiologiques) utilisées pour la reconnaissance des émotions.
2. Comparer les performances (précision, méthodes, dataset) des approches unimodales et multimodales.

2. RÉSULTATS ET AMÉLIORATIONS CIBLÉES

Résultats clés :

- Les systèmes **multimodaux** (combinaison de plusieurs signaux comme audio + texte ou EEG + expressions faciales) surpassent les approches unimodales en précision (ex. : 80.5% sur IEMOCAP avec DCNN + SincNet).
- Les techniques de **fusion** (early fusion, late fusion, attention cross-modale) améliorent la robustesse.
- Les signaux physiologiques (ECG, EEG) sont efficaces pour capturer des émotions fugaces (3-15 secondes).

Améliorations identifiées :

- Extraction de caractéristiques plus robustes (p. ex., pour les expressions faciales avec des variations culturelles).
- Optimisation des temps de calcul (réduction de la complexité des modèles).

Modèles utilisés et techniques de fusion:


- **Modèles utilisés :**
 - **CNN** pour les images et l'audio ([Chen et al.], [Krishna et al.]).
 - **LSTM** pour les séquences temporelles (EEG, audio) ([Nie et al.], [Yang et al.]).
 - **SVM** pour la fusion multimodale ([Caihua]).
 - **Transformers (BERT)** pour le traitement du texte ([Siriwardhana et al.]).
- **Techniques de fusion :**
 - Attention cross-modale** ([Pan et al.], [Krishna et al.]).
 - Fusion hiérarchique** (early vs. late fusion) ([Nakisa et al.]).

CONCLUSION

Pour conclure, cet article met en lumière l'importance croissante de la reconnaissance des émotions multimodales dans le paysage technologique actuel. En combinant des données variées comme les expressions faciales, la voix et les signaux physiologiques avec des techniques avancées de deep learning, les chercheurs parviennent à développer des systèmes plus précis et adaptatifs. Ces avancées ouvrent la voie à des applications innovantes, que ce soit dans les domaines de la santé, de l'éducation ou des interfaces humain-machine. Cependant, des défis persistent, notamment pour améliorer la robustesse des modèles face à la diversité culturelle et contextuelle.

MULTIMODAL EMOTION RECOGNITION IN RESPONSE TO VIDEOS

LECTURE MULTIMODALE




TEXTES



AUDIO




CARTES/
GRAPHIQUES



SITES
INTERNET



IMAGES/
PHOTOS



FILMS/
VIDÉOS

1. Objectif principal

L'article propose une méthode de reconnaissance d'émotions indépendante de l'utilisateur en combinant des signaux physiologiques (EEG, pupillométrie, suivi du regard) pour étiqueter automatiquement des vidéos selon leur contenu émotionnel.

2. Méthodologie

1. Données :


- 24 participants ont visionné 20 clips vidéo (émotions variées : calme, plaisir, dégoût, etc.).
- Signaux enregistrés : EEG (32 électrodes), diamètre pupillaire, distance du regard.
- Vérité terrain : annotations manuelles (valence/arousal) via un questionnaire en ligne.

2. Traitement des signaux :

- EEG : Analyse des bandes spectrales (theta, alpha, beta, gamma) et asymétries hémisphériques.
- Pupillométrie : Suppression de l'effet lumineux via PCA pour isoler la réponse émotionnelle.
- Regard : Taux de clignement des yeux, distance à l'écran (approche/évitement).

MULTIMODAL EMOTION RECOGNITION IN RESPONSE TO VIDEOS

LECTURE MULTIMODALE




TEXTES



AUDIO




CARTES/
GRAPHIQUES



SITES
INTERNET



IMAGES/
PHOTOS



FILMS/
VIDÉOS

3.classification :

- **SVM** avec noyau RBF pour classer 3 catégories d'arousal (calme, moyen, activé) et de valence (déplaisant, neutre, plaisant).
- **Fusion multimodale** :
 - **Feature-Level Fusion (FLF)** : Concatenation des caractéristiques.
 - **Decision-Level Fusion (DLF)** : Combinaison des probabilités de sortie des classifieurs.


3. Résultats clés:

1. Performance :

- **DLF** atteint **76.4%** de précision pour l'arousal et **68.5%** pour la valence, surpassant les approches unimodales (EEG seul : 62.1%, regard seul : 71.1%).
- Meilleure détection de l'**arousal** (lié aux stimuli visuels/auditifs forts) que de la **valence** (plus subtile, dépendante du contexte sémantique).

MULTIMODAL EMOTION RECOGNITION IN RESPONSE TO VIDEOS

LECTURE MULTIMODALE




TEXTES



AUDIO




CARTES/
GRAPHIQUES



SITES
INTERNET



IMAGES/
PHOTOS



FILMS/
VIDÉOS

2. Comparaison avec l'auto-évaluation :

- La méthode surpasse les auto-reports pour l'arousal (55.7% de précision humaine vs. 76.4%).
- Performance similaire pour la valence (69.4% vs. 68.5%).

4. Innovations et améliorations:

1. Contribution algorithmique:

- **Fusion DLF optimisée** : Utilisation des probabilités postérieures des SVM (méthode de Platt) pour pondérer les décisions multimodales.
- **PCA pour la pupillométrie** : Extraction robuste de la réponse émotionnelle malgré les artefacts lumineux.

2. Améliorations par rapport à l'état de l'art :

- Première étude à combiner **EEG + pupillométrie + regard** pour l'étiquetage affectif de vidéos.
- Validation sur une dataset public (disponible en ligne), favorisant la reproductibilité.

CONCLUSION

Cet article cible une amélioration algorithmique via une fusion multimodale innovante (DLF) et démontre son efficacité pour la reconnaissance d'émotions induites par des vidéos. Les résultats valident l'approche pour des applications pratiques (ex. tagging implicite de contenus), mais soulignent le besoin d'étendre les données et de réduire les biais contextuels.

Un grand merci
POUR VOTRE ATTENTION !