

Détection des émotions: Améliorations des modèles d'apprentissage automatique

Réaliser par: Asma BenZaied






À PROPOS

Le projet mené dans le cadre du **stage chez DOURBIA**, notre objectif est de développer un **outil d'aide à la décision innovant pour l'analyse des émotions à partir d'un discours multimodal (voix, texte, gestes et expressions faciales)** qui permettra d'assister les experts dans le diagnostic des **pathologies émotionnelles**





Grâce à l'utilisation de techniques avancées de **Machine Learning** et de **fusion multimodale** voici résultat trouve:

- **Analyse vocale (DCNN → 96,05% de précision)**
- **Analyse textuelle (BERT → 75%, performance à améliorer)**
- **Analyse des émotions (BI-GRU → 93,48%)**
- **Analyse visuelle (SVM → 98,74%)**



PROBLÉMATIQUE

1. La performance **du modèle textuel BERT est faible (75%)** comparée aux autres modalités, ce qui peut impacter la robustesse de la fusion multimodale.
2. On peut **optimiser l'approche actuelle de fusion** en utilisant des techniques récentes tirées de la littérature scientifique afin d'améliorer la complémentarité entre les modalités.
3. **Le problème lié au dataset** réside dans le manque d'équilibre et de qualité entre les différentes modalités, ce qui peut compromettre la cohérence des résultats obtenus lors de la fusion multimodale.



MODÈLE TEXTUEL

la classification des émotions en texte

RoBERTa:

Explication: Version optimisée de BERT avec un pré-entraînement plus robuste.

Article: <https://arxiv.org/abs/1907.11692>

Performance typique : 78–82% F1-score.


Dataset: GoEmotions: A Dataset for Fine-Grained Emotion Classification

<https://research.google/blog/goemotions-a-dataset-for-fine-grained-emotion-classification/>

Article: <https://arxiv.org/abs/2005.00547>

Analyse du dataset:

- Le dataset GoEmotions contient 27 catégories d'émotions distinctes et une catégorie Neutre.



MODÈLE TEXTUEL

la classification des émotions en texte

- **But** : Aller bien au-delà des 6 émotions de base (joie, tristesse, peur, colère, surprise, dégoût) pour capturer des nuances plus riches.
- **Analyse du data et résultat obtenu** : a partir du analyse du data en remarque que **les émotions ne sont pas uniformément réparties** et que **les émotions positives sont fréquentes**, d'où l'utilisation d'une taxonomie plus diversifiée que les six émotions de base traditionnelles

Google Research

Who we are ▾

Research areas ▾


Our work ▾

Programs & events ▾

Careers

Data Analysis and Results

Emotions are not distributed uniformly in the GoEmotions dataset. Importantly, the high frequency of positive emotions reinforces our motivation for a more diverse emotion taxonomy than that offered by the canonical six basic emotions.



MODÈLE TEXTUEL

la classification des émotions en texte

DeBERTa (V3) – State-of-the-art en 2023

Explication: DeBERTa signifie Decoding-enhanced BERT and RoBERT with disentangled attention.

C'est une version améliorée de BERT et RoBERTa, un célèbre modèle de traitement du langage naturel (NLP).

Article: <https://arxiv.org/abs/2006.03654>

Performance typique: 80–83 % de F1-score

Dataset: IEMOCAP

<https://paperswithcode.com/dataset/iemocap>

<https://sail.usc.edu/iemocap/>


<https://www.kaggle.com/datasets/samuelsamsudinng/iemocap-emotion-speech-database>

Analyse du dataset:

- IEMOCAP comprend **151 vidéos de dialogues enregistrés**, avec 2 locuteurs par session, pour un total de 302 vidéos dans l'ensemble du corpus. Chaque segment est annoté pour **la présence de 9 émotions (colère, excitation, peur, tristesse, surprise, frustration, joie, déception et neutre)** ainsi que pour la valence, l'éveil et la dominance. Les enregistrements ont été réalisés sur 5 sessions avec 5 paires de locuteurs différents.
-

MODÈLE TEXTUEL

la classification des émotions en texte



TITRE: Architecture du modèle DeBERTa pour la classification des émotions textuelles

Caractéristique	IEMOCAP
Taille	~12 heures de données
Nombre d'émotions	Plus de 10 émotions
Contexte conversationnel	très riche
Multimodalité	audio, vidéo, texte
Qualité des données	Très élevée

TITRE: Tableau récapitulatif des caractéristiques du dataset IEMOCAP



MODÈLE TEXTUEL

la classification des émotions en texte

EmoRoBERTa: Modèle spécialisé émotions

Explication: EmoRoBERTa est un modèle de traitement du langage (NLP) spécialisé dans la classification des émotions à partir de textes. Il est basé sur RoBERTa, lui-même une amélioration de BERT, mais adapté spécifiquement sur des données émotionnelles .

lien: <https://huggingface.co/j-hartmann/emotion-english-distilroberta-base>

Performance typique: 85% F1-score

Dataset: IEMOCAP ou MELD

PROPOSITION

1. D'où pour mettre en œuvre une fusion multimodale efficace, en utilisant des données réelles et des modèles récentes soutenus par la recherche on peut utiliser le dataset "**IEMOCAP**" ou "**MELD**"

lien de téléchargement du dataset: https://sail.usc.edu/iemocap/?spm=a2ty_o01.29997173.0.0.3dc9c921hKN1ej

https://github.com/declare-lab/MELD?spm=a2ty_o01.29997173.0.0.3dc9c921hKN1ej

2. Modèle d'apprentissage multimodal: **MISA (Modality-Invariant and -Specific Representations for Multimodal Sentiment Analysis) (Rahman et al., 2020)**

- il s'agit d'une architecture moderne de fusion multimodale .
- un modèle de représentation multimodale avec séparation invariant/spécifique.
- Elle utilise l'attention croisée pour mieux aligner les modalités.
- Très performante sur IEMOCAP/MELD.
- MISA gère bien les déséquilibres .

lien: <https://arxiv.org/abs/2009.00442>



PROPOSITION



D'où nouveau pipeline multimodal proposé:

Voix	DCNN(96,05%)
Texte	EmoRoBERTa (BERT → 75% EmoRoBERTa ~85%)
Visuel	ResNet + SVM(98,74%)
Emotions	OpenPose + BI-GRU(93,48M%)

TITRE: Structure du nouveau pipeline multimodal

TABLEAU

Modalité	MELD	IEMOCAP
Audio	Oui	Oui
Texte	Oui	Oui
Vidéo (visage)	Oui	Oui
Annotations émotionnelles	Oui (7 émotions)	Oui (6–10 émotions)
Expressions faciales	Oui	Oui
Gestes / posture du corps	Non	Oui (motion capture 3D)

Taille du dataset	Taille du dataset ~6 Go	~50–60 Go
Accès	GitHub (direct)	via Formulaire et email

TITRE: Tableau comparatif des Modalités disponibles dans MELD vs IEMOCAP

CONCLUSION

Afin de pallier le manque de bases de données multimodales, nous avons utilisé IEMOCAP ou MELD ,un dataset de référence contenant des enregistrements synchronisés de voix, texte, visage et gestes, annotés en émotions. Pour la fusion, nous avons adopté MISA (Rahman et al., 2020), une architecture récente qui sépare les représentations modales spécifiques et partagées, permettant une meilleure intégration des signaux hétérogènes. Le module textuel a été amélioré en remplaçant BERT par EmoRoBERTa , un modèle spécialisé dans la détection des émotions, passant de 75% à ~85% de précision.



**Merci pour votre
attention**